中国交建
CHINA COMMUNICATIONS CONSTRUCTION

可解释性机器学习在工程中的应用

技术中心 智能监控技术部

肖垚

二〇二二年十一月

让世界更畅通

CONTENTES

目录

01 研究动机(Motivation)

02 研究方法(Methology)

03 应用案例(Application)

04 总结致谢(Acknowledgement)

中国交建 CHINA COMMUNICATIONS CONSTRUCTION

研究背景

- 国务院《**新一代人工智能发展规划的通知**》提出构筑AI发展先发优势，加快建设新型国家和世界科技强国；
- 信通院《**数字建筑发展白皮书**》提出要大力布局推广智能生产、智慧工地、智能审查等典型应用；
- 省经信厅《**湖北省人工智能产业“十四五”发展规划**》提出加快发展省AI产业，推动经济社会高质量发展；
- 作为实现人工智能的关键路径之一，机器学习在各行业中有着丰富的应用场景。

轨道交通——钢轨缺陷检测

制造业——产品缺陷检测

能源——用电量预测

金融——银行授信风险识别

中国交建 CHINA COMMUNICATIONS CONSTRUCTION

研究意义

- 机器学习(Machine Learning, ML)系统呈现给用户的仅为输入、输出接口，其内部为一个黑箱(Black box)。在常规任务上，结果差强人意；但对于高风险决策(high stakes decisions)场景，“高精度”黑箱系统似乎并不可靠。

输入

ML模型(ML Models)

人类大脑(Brain)

Normal(96%)
断裂(100%)

输出

- 系统为什么会给出这样的判别结果?
- 如何根据系统的判别结果进行反馈并提升系统性能?
- 如何提升ML系统的可用性?

可解释性机器学习
(Explainable ML)

中国交建 CHINA COMMUNICATIONS CONSTRUCTION

基本定义

- 机器学习模型的可解释性(Interpretability)越高，用户就越容易理解ML系统做出这样或那样决策的原因。换言之，如若一个模型的决策相较于另一个模型的决策更容易为人理解，则该模型就相对具有更好的可解释性。

[Kim, Been. Et.al 2016]

Interpretability is the degree to which a human can consistently predict the model's result.

[Miller, Tim. Et.al 2017]

Interpretability is the degree to which a human can understand the cause of a decision.

CONTENTES

目录

01 研究动机(Motivation)

02 研究方法(Methology)

03 应用案例(Application)

04 总结致谢(Acknowledgement)

模型解释方法

- 机器学习模型可解释性方法总体上分为3类：基于Ante-hoc(**事前可解释性**)的方法、基于Post-hoc(**事后可解释性**)的方法以及基于Knowledge Graph(**知识图谱**)的方法。
- 一般而言，**模型的复杂度与模型准确性相关联，又与模型的可解释性相对立**(不存在绝对关系)。

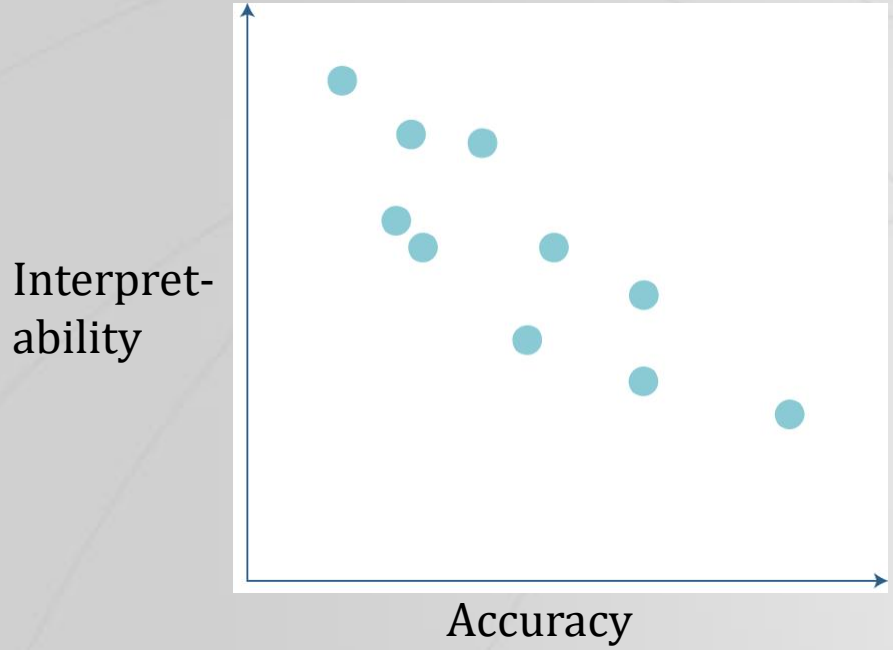

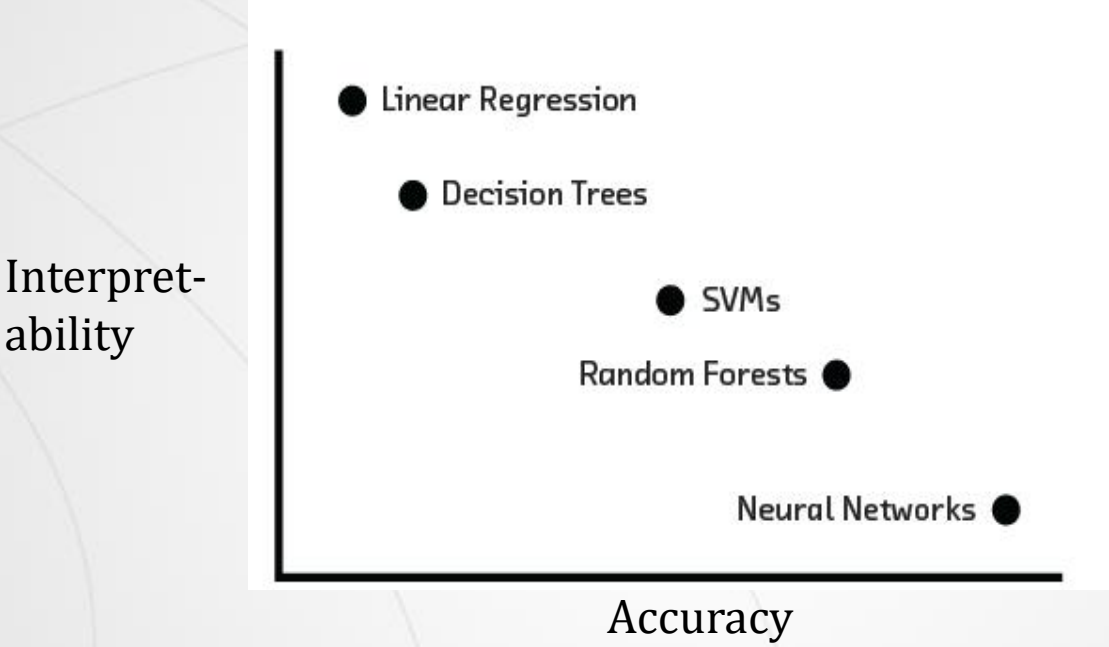

In ***certain*** settings, *accuracy-interpretability trade offs* may exist.

事前解释法

- 基于Ante-hoc(**事前可解释性**)的方法：即使用结构简单而复杂度低的算法，建立自身具有可解释性的模型；比如：Naïve Bayes、Linear Regression、Decision Trees、基于规则的算法等；

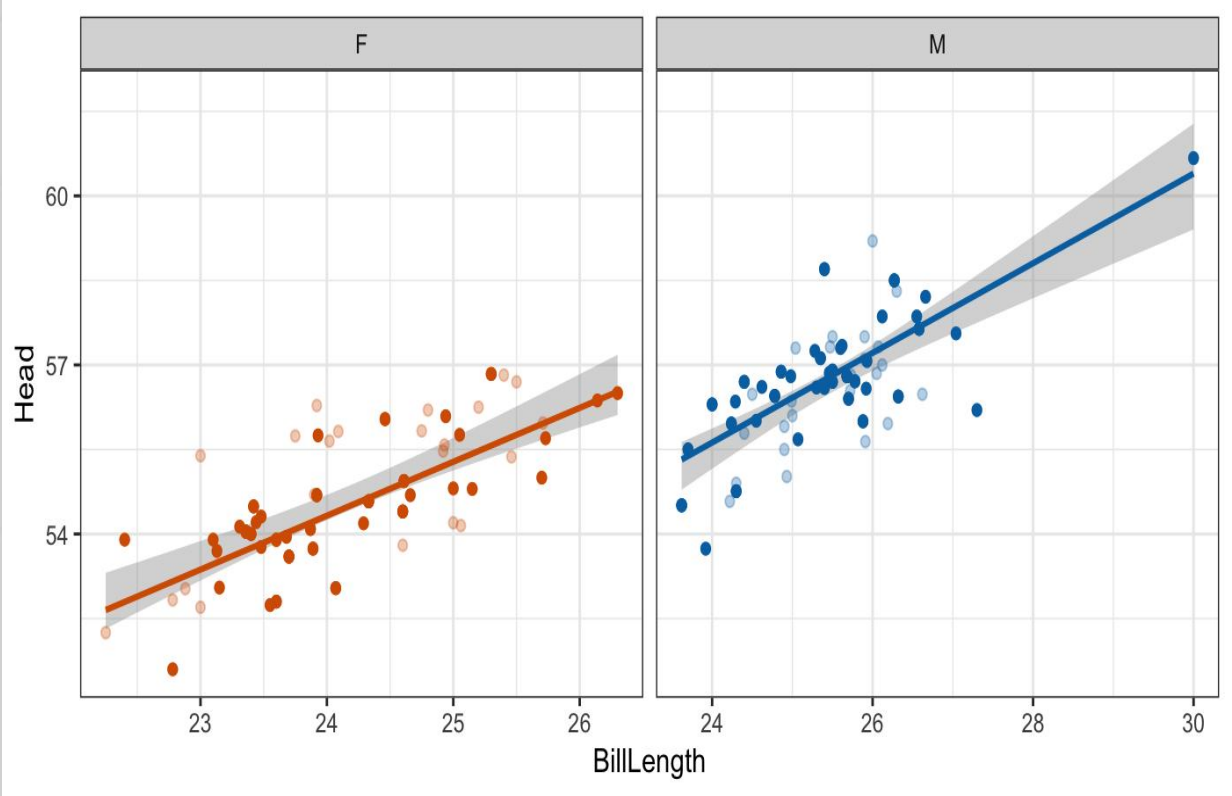

if $(age = 18 - 20)$ **and** $(sex = male)$ **then predict** yes
else if $(age = 21 - 23)$ **and** $(priors = 2 - 3)$ **then predict** yes
else if $(priors > 3)$ **then predict** yes
else predict no

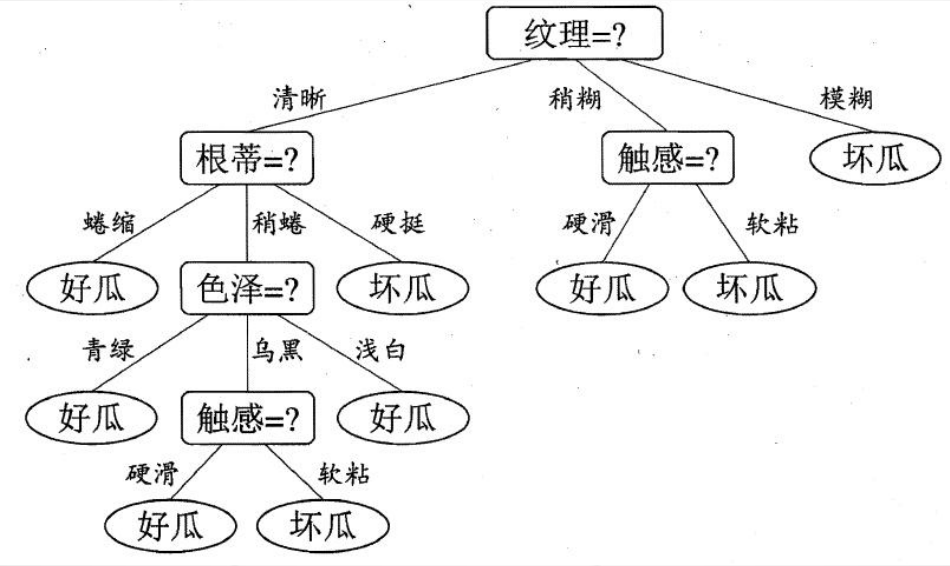

2. 研究方法——基于神经网络的图像分类(回顾)

图像分类

- 以分辨率为255*255的三通道图像为例，原始图像为255*255*3的矩阵。卷积神经网络CNN通过卷积核/滤波器对输入图像进行卷积操作，以替代人工实现特征抽取；然后利用分类器进行类别判定，判定函数如交叉熵等。

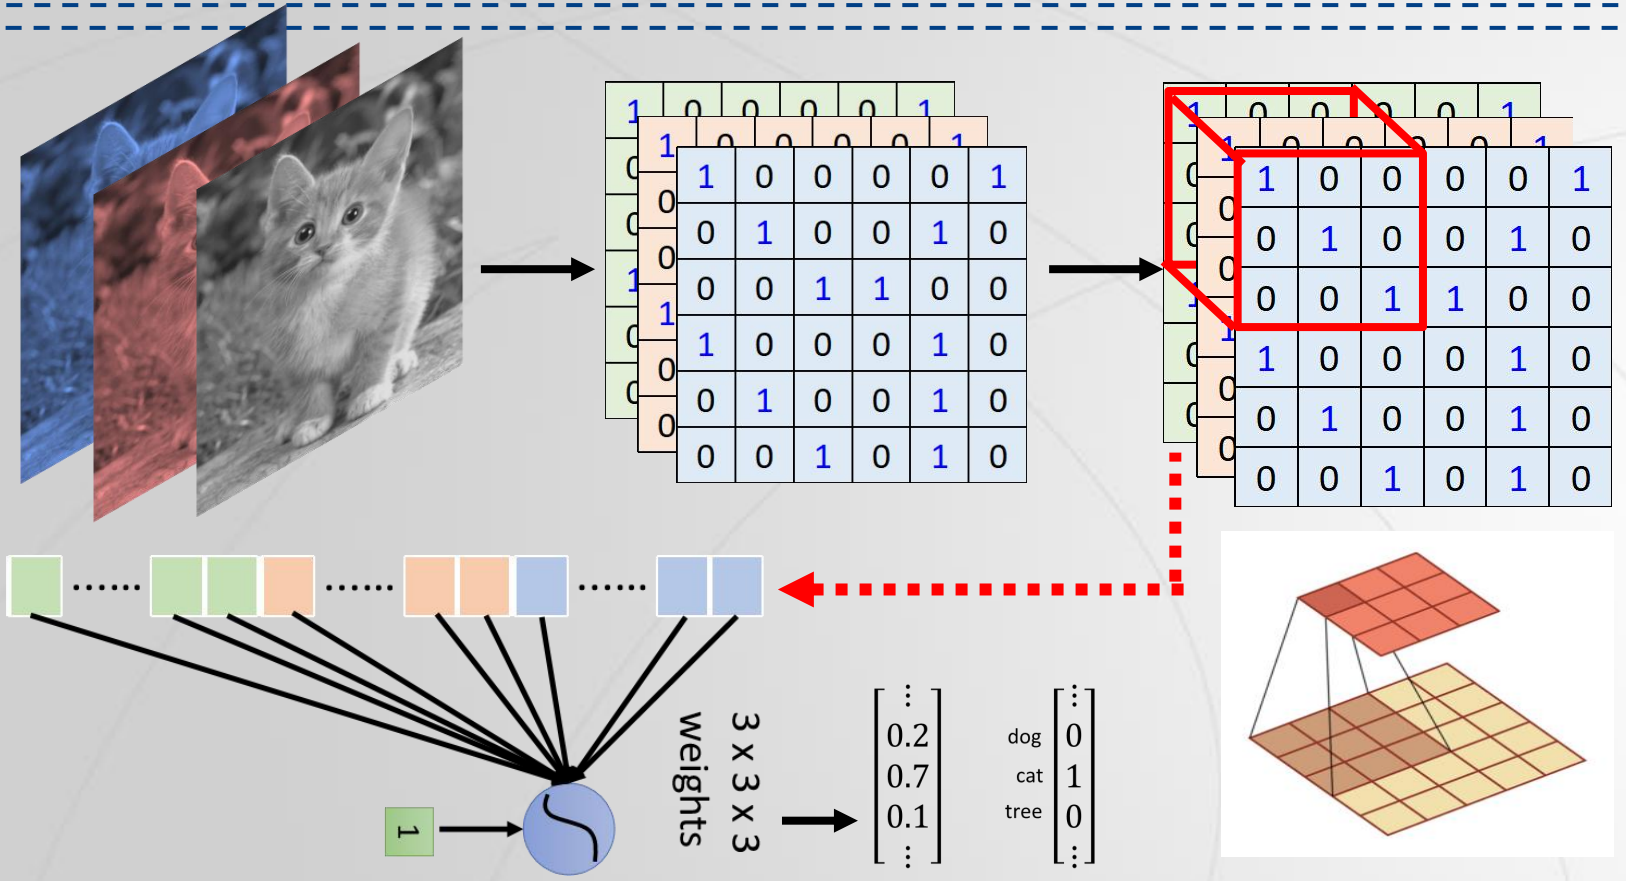

事后解释法

- 基于Post-hoc(**事后可解释性**)的方法：即使用模型可解释性方法或构建解释模型，对用户所构建模型的工作机制、决策行为和决策依据进行解释。这类方法又分为全局可解释性(如模型蒸馏)和局部可解释性(如CAM)方法；

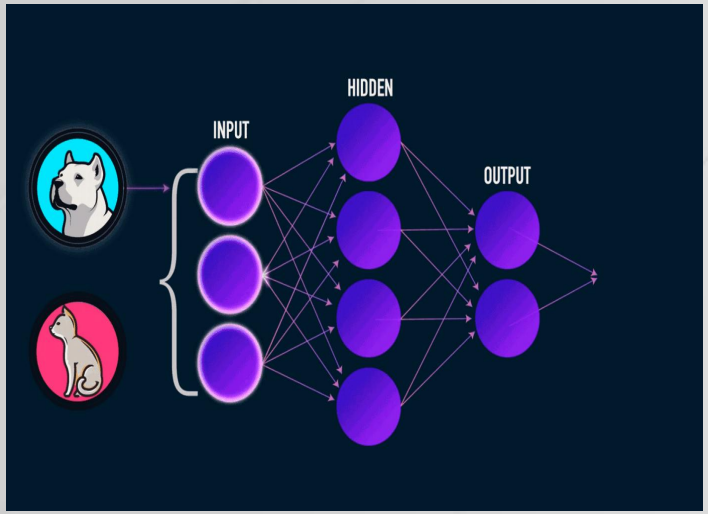

解释器
(Explainer)

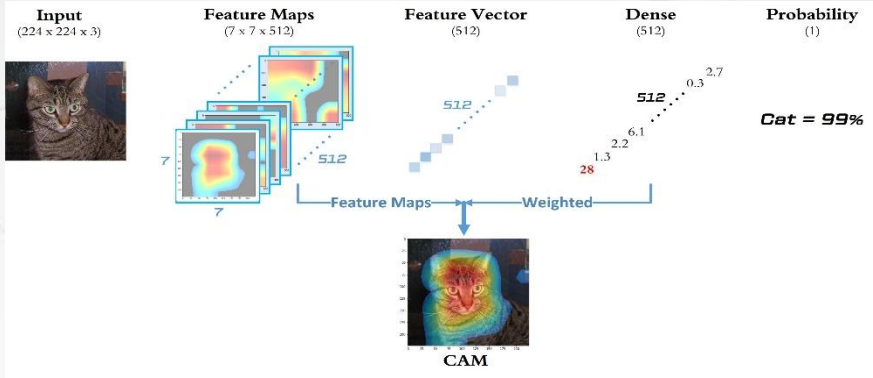

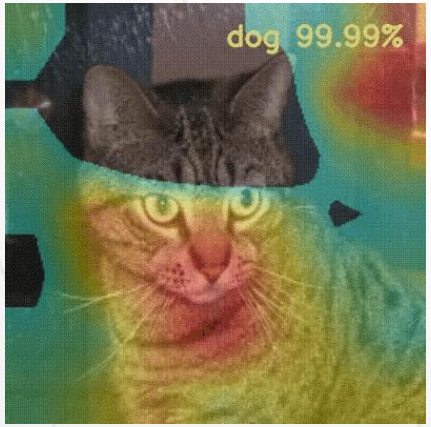

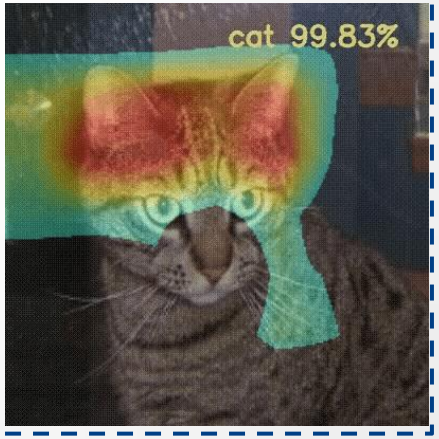

事后解释法

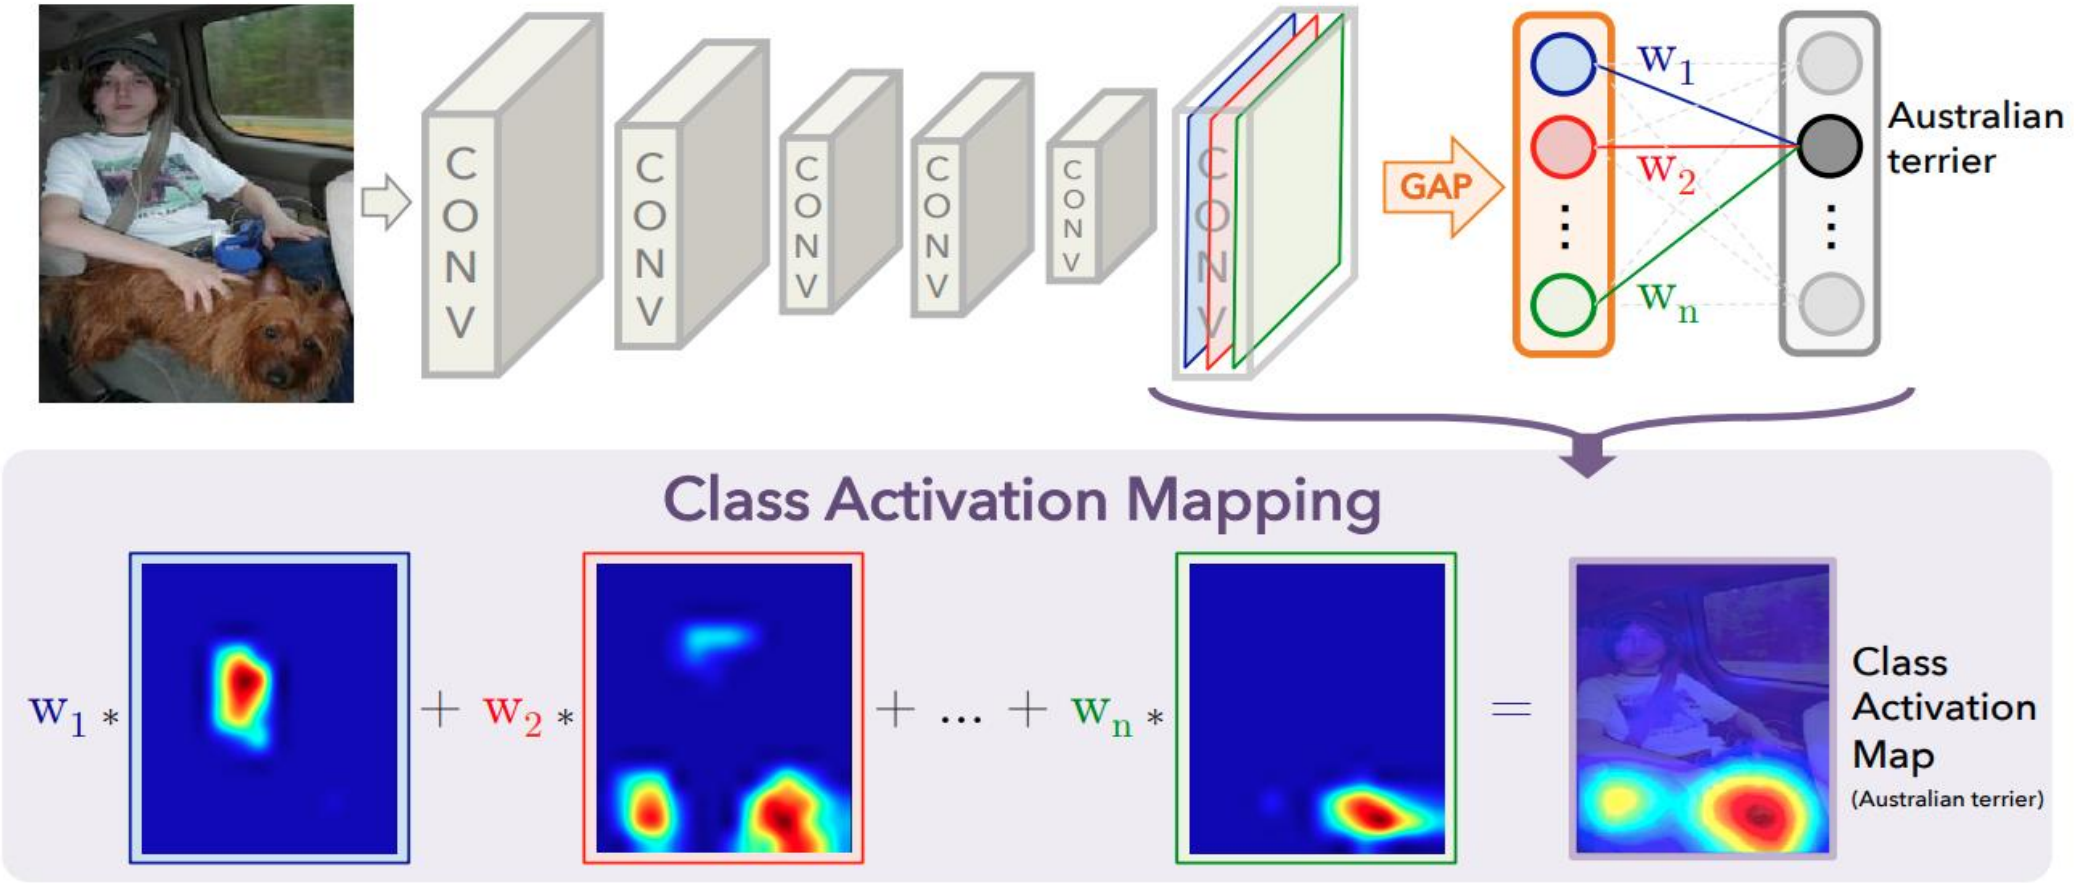

Figure 2. Class Activation Mapping: the predicted class score is mapped back to the previous convolutional layer to generate the class activation maps (CAMs). The CAM highlights the class-specific discriminative regions.

2. 研究方法——2.2.1 事后解释法之局部可解释性

局部可解释性

- 局部可解释性(Local Explanations)：**以输入样本为导向**，通常可以通过分析输入样本的每一维特征对模型最终决策结果的贡献来实现。由于模型算法的不透明性、模型结构的复杂性以及应用场景的多元性，提供对机器学习模型的全局解释通常比提供局部解释更困难。局部解释方法相对于全局解释方法也更常见。经典的局部解释方法包括敏感性分析解释、局部近似解释、梯度反向传播解释、特征反演解释以及类激活映射解释等。

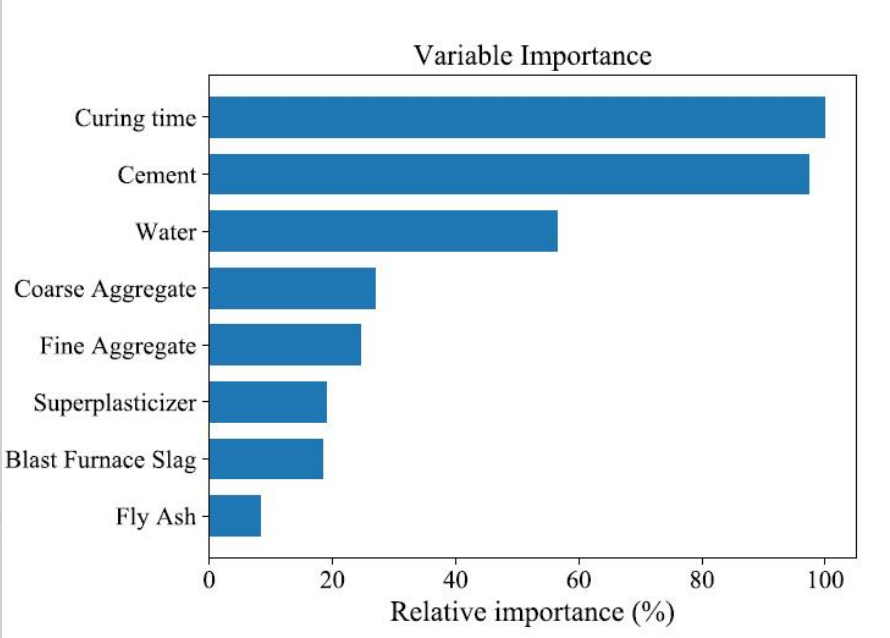

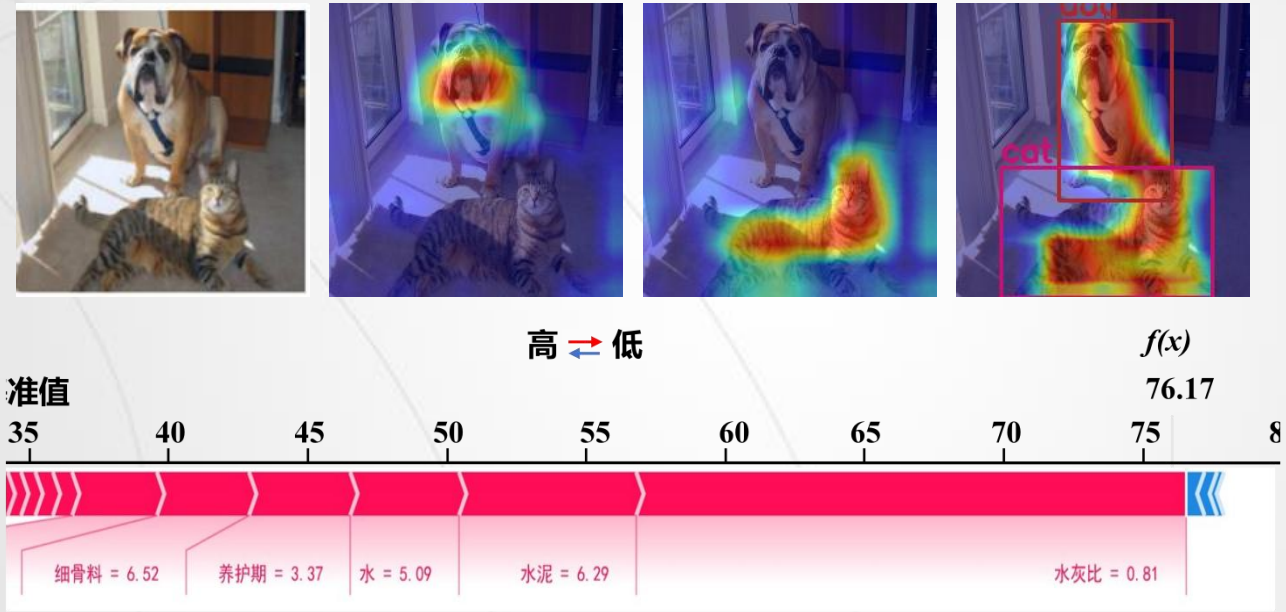

全局可解释性

- 全局可解释性(Local Explanations)：旨在帮助人们从整体上**理解模型背后的复杂逻辑以及内部的工作机制**，例如模型是如何学习的、模型从训练数据中学到了什么、模型是如何进行决策的等，这要求我们能以人类可理解的方式来表示一个训练好的复杂学习模型。**典型的全局解释方法包括解释模型/规则提取、模型蒸馏、激活最大化解释等。**

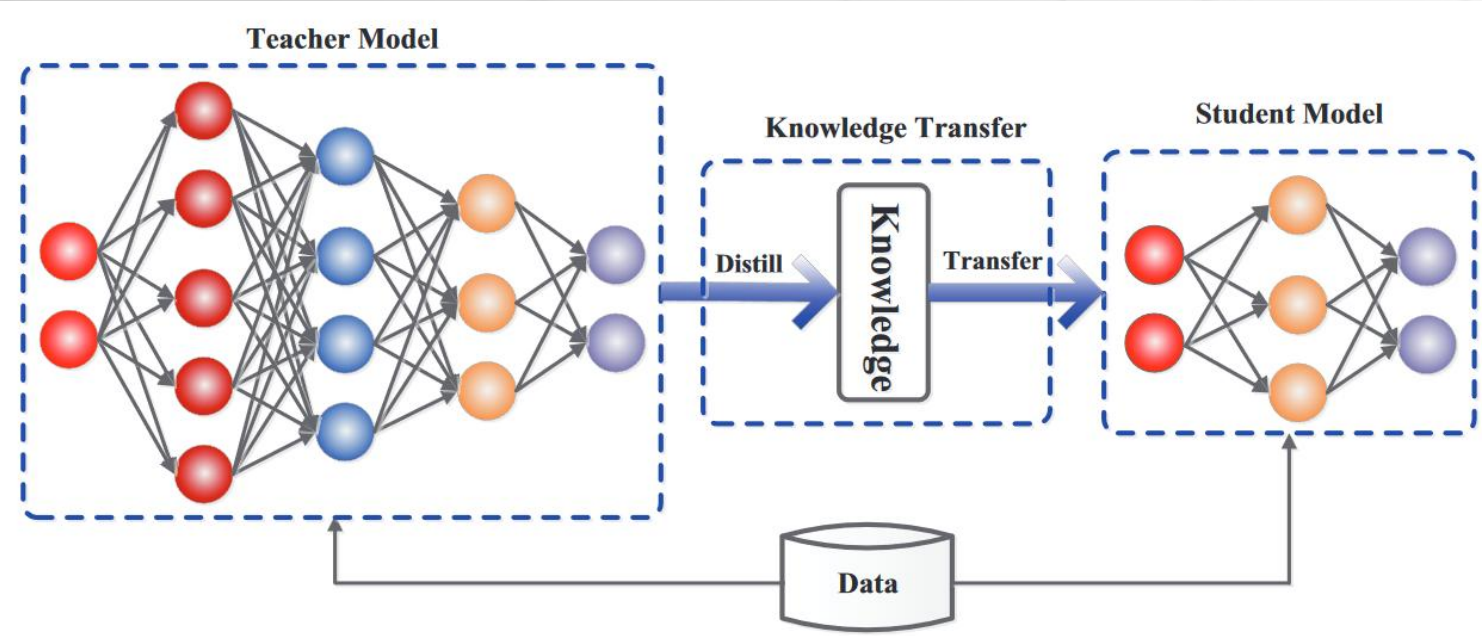

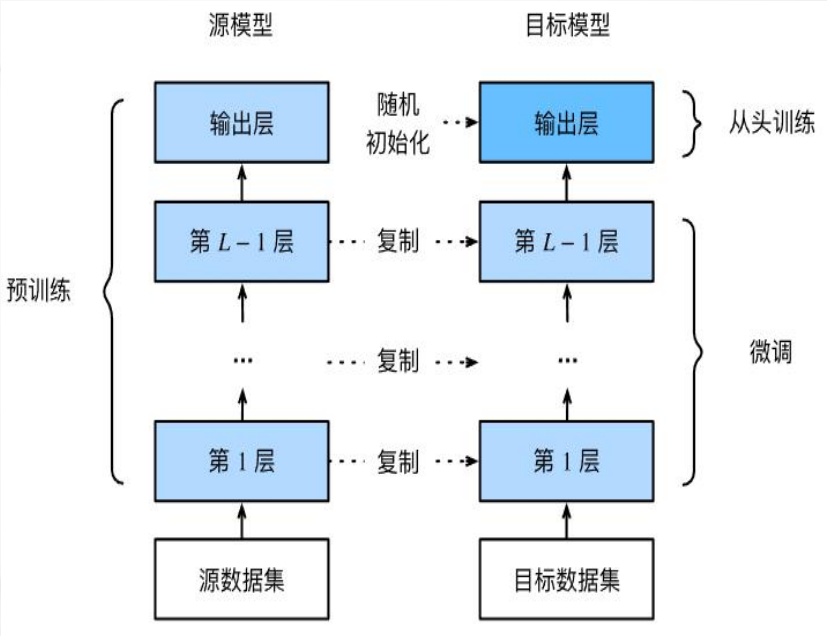

中国交建 CHINA COMMUNICATIONS CONSTRUCTION

知识图谱

- 基于Knowledge Graph(**知识图谱**)的方法：即利用知识图谱的链路关联关系，实现知识推理，进而实现对学习模型决策结果的解释，常用于对推荐算法的解释(**基于知识的可解释推荐**)。

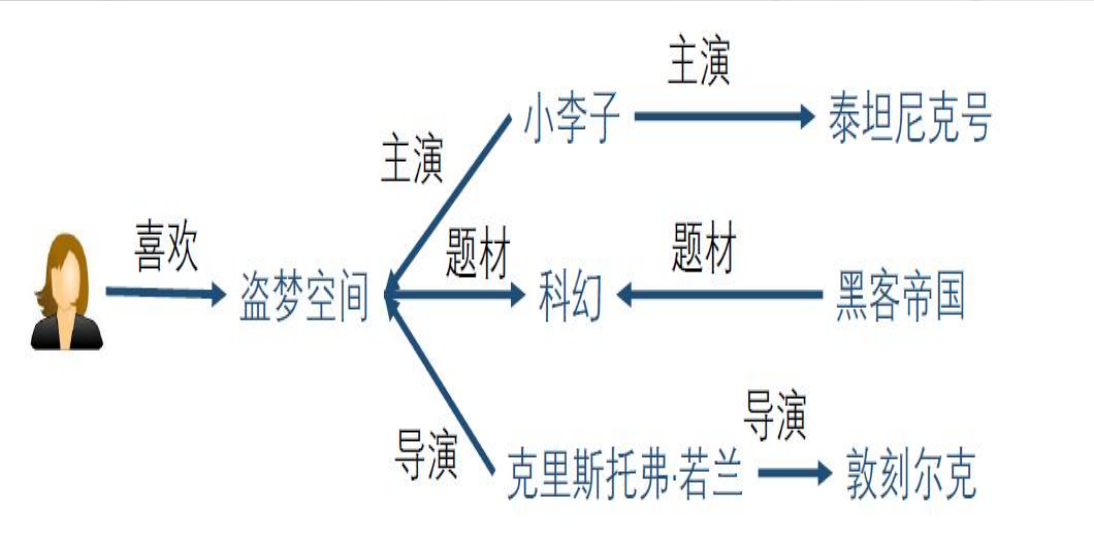

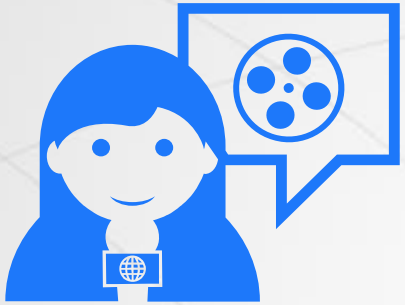

喜欢

Maybe like：

泰坦尼克号，因为它们有相同的主演；

黑客帝国，因为它们有相同的题材；

敦刻尔克，因为它们有相同的导演；

2. 研究方法——2.4 常用的解释性分析工具

分析工具

[interpretability-methods-in-machine-learning-a-brief-survey]

- 常用的一体化封装式可解释性分析工具包主要有：[SHAP]、[shapash]、[LIME]、 [captum]、[interpret.ml]等。

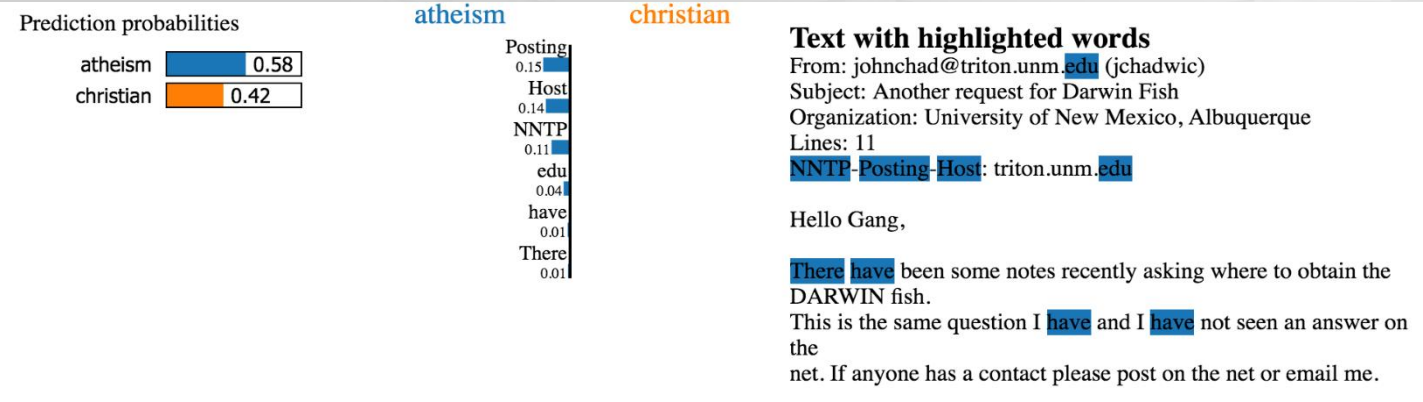

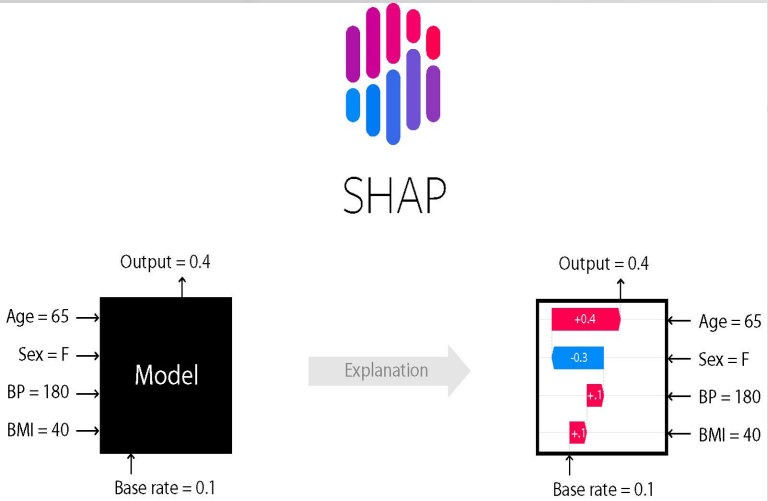

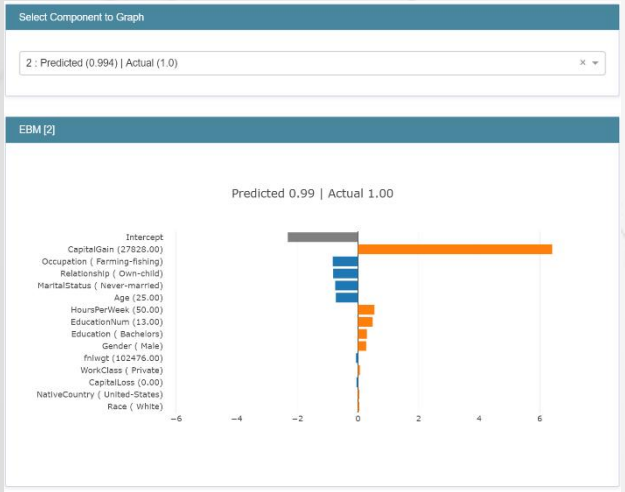

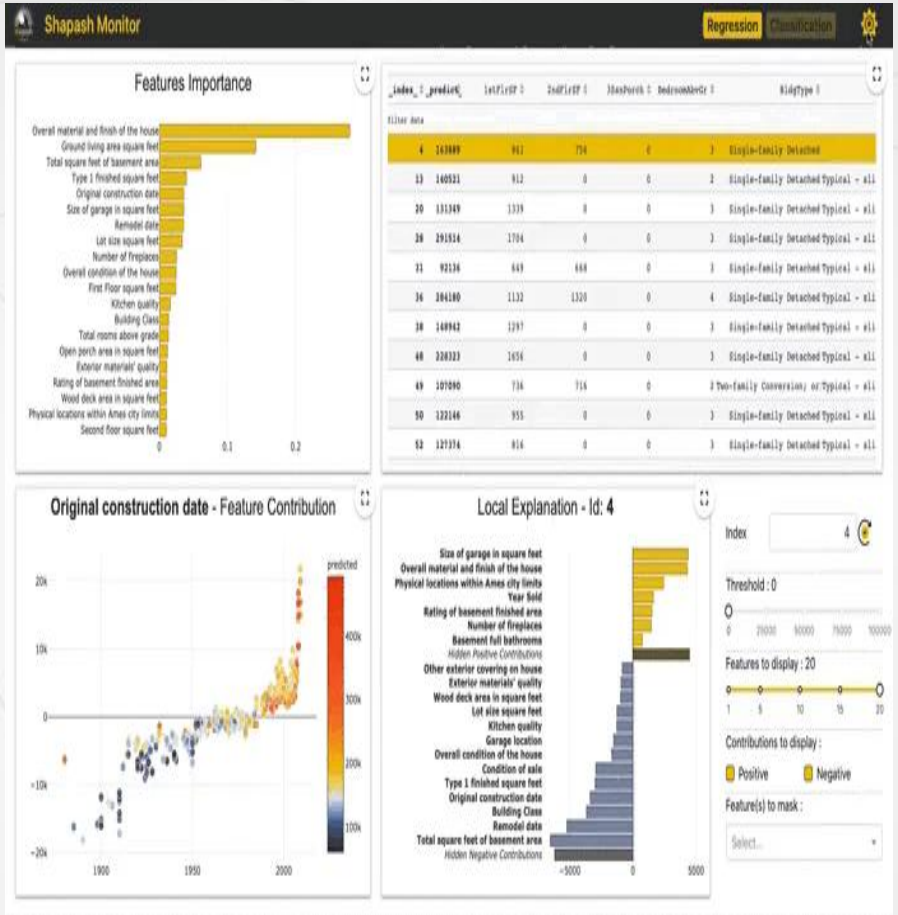

中国交建 CHINA COMMUNICATIONS CONSTRUCTION

SHAP原理

[shapley-values-reference-Link]

- 作为一种经典的解释框架， SHAP通过计算出每个特征变量的贡献值(Shapley Value)，实现解释的目的。将数据集的每个特征变量均视为游戏玩家，则Shapley Value主要是用来解决合作**博弈论**中的分配均衡问题。计算如下:

假设合作项目 Proj=<Players, v>， Players={1,2,...n}, v是贡献量的特征方程；那么，定义项目Proj=500行代码，由玩家程序员1,2,3完成。若独立进行：每个玩家可以独立完成的代码量为：$v(\{1\}) = 100, v(\{2\}) = 125, v(\{3\}) = 50$

；**若合作进行**：$v(\{1,2\}) = 270, v(\{2,3\}) = 350, v(\{1,3\}) = 375$ **且满足**：$v(\{1,2,3\}) = 500$ ；具体合作情况：如果我们要合理分配，是否公平主要看边际贡献。

1 → 2 → 3
1 → 3 → 2
2 → 1 → 3
2 → 3 → 1
3 → 1 → 2
3 → 2 → 1

先定义第i个玩家加入组织S的边际贡献 $\delta(i) = v(S \cup \{i\}) - v(S)$

挑选第一种情况为例：

玩家1边际贡献: $v(\{1\}) = 100$

玩家2边际贡献: $v(\{1,2\}) - v(\{1\}) = 270 - 100 = 170$

玩家3边际贡献: $v(\{1,2,3\}) - v(\{1,2\}) = 500 - 270 = 230$

SHAP原理

- 按照上面的计算过程，依次计算剩下的5种情况。同时考虑到这6种情况是等概率出现的。完整结果如下表：

概率	玩家加入顺序	玩家1的边际贡献	玩家2的边际贡献	玩家3的边际贡献
$\frac{1}{6}$	1,2,3	100	170	230
$\frac{1}{6}$	1,3,2	100	125	275
$\frac{1}{6}$	2,1,3	145	125	230
$\frac{1}{6}$	2,3,1	150	125	225
$\frac{1}{6}$	3,1,2	325	125	50
$\frac{1}{6}$	3,2,1	150	300	50

$$v(\{1\}) = 100, v(\{2\}) = 125, v(\{3\}) = 50$$

- 计算第i个玩家的Shapley Value, 主要是由上表的边际贡献得到：

玩家	Shapley Value
1	$\frac{1}{6}(100+100+145+150+325+150)=\frac{970}{6}$
2	$\frac{1}{6}(170+125+125+125+125+300)=\frac{970}{6}$
3	$\frac{1}{6}(230+275+230+225+50+50)=\frac{1060}{6}$

CONTENTES

目录

01 研究动机(Motivation)

02 研究方法(Methology)

03 应用案例(Application)

04 总结致谢(Acknowledgement)

中国交建 CHINA COMMUNICATIONS CONSTRUCTION

强度预测

- 基于Boost框架建立高性能混凝土抗压强度预测模型并利用SHAP算法对强度预测模型进行可解释性分析。

安装： pip install shap *or* conda install -c conda-forge shap

使用：

```
import xgboost
import shap

# train an XGBoost model
X, y = shap.datasets.boston()
model = xgboost.XGBRegressor().fit(X, y)

# explain the model's predictions using SHAP
# (same syntax works for LightGBM, CatBoost, scikit-learn, transformers, Spark, etc.)
explainer = shap.Explainer(model)
shap_values = explainer(X)

# visualize the first prediction's explanation
shap.summary_plot(shap_values[:100,:], X.iloc[:100,:])
```

Cement (component 1)(kg in a m^3 mixture)	Blast Furnace Slag (component 2)(kg in a m^3 mixture)	Fly Ash (component 3)(kg in a m^3 mixture)	Water (component 4)(kg in a m^3 mixture)	Superplasticizer (component 5)(kg in a m^3 mixture)	Coarse Aggregate (component 6)(kg in a m^3 mixture)	Fine Aggregate (component 7)(kg in a m^3 mixture)	Age (day)	Concrete compressive strength(MPa, megapascals)
540.0	0.0	0.0	162.0	2.5	1040.0	676.0	28	79.99
540.0	0.0	0.0	162.0	2.5	1055.0	676.0	28	61.89
332.5	142.5	0.0	228.0	0.0	932.0	594.0	270	40.27
332.5	142.5	0.0	228.0	0.0	932.0	594.0	365	41.05
198.6	132.4	0.0	192.0	0.0	978.4	825.5	360	44.30
266.0	114.0	0.0	228.0	0.0	932.0	670.0	90	47.03
380.0	95.0	0.0	228.0	0.0	932.0	594.0	365	43.70
380.0	95.0	0.0	228.0	0.0	932.0	594.0	28	36.45
266.0	114.0	0.0	228.0	0.0	932.0	670.0	28	45.85
475.0	0.0	0.0	228.0	0.0	932.0	594.0	28	39.29
198.6	132.4	0.0	192.0	0.0	978.4	825.5	90	38.07

强度预测

- 在当前数据集中，随着养护期的增加，抗压强度平均会有大约16 Mpa的提升，，，。

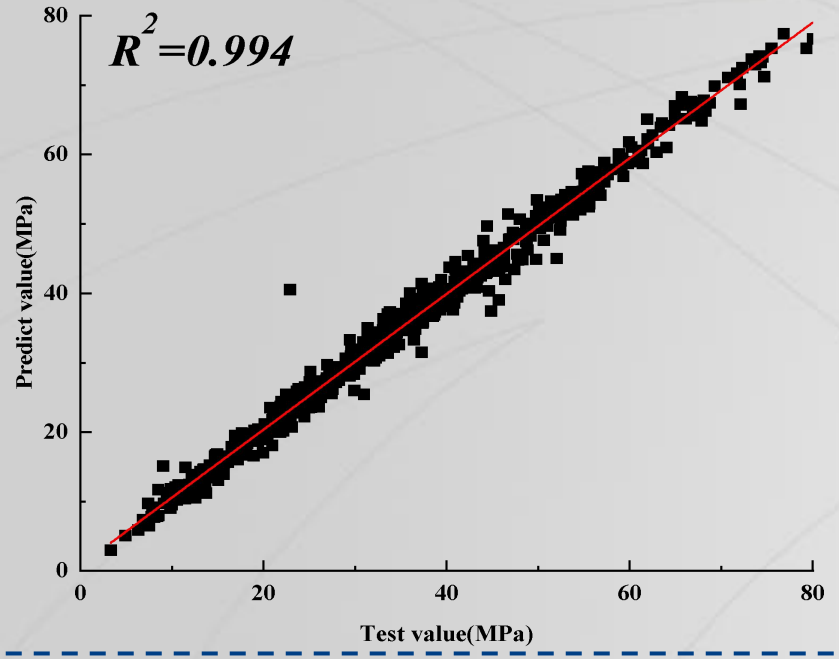

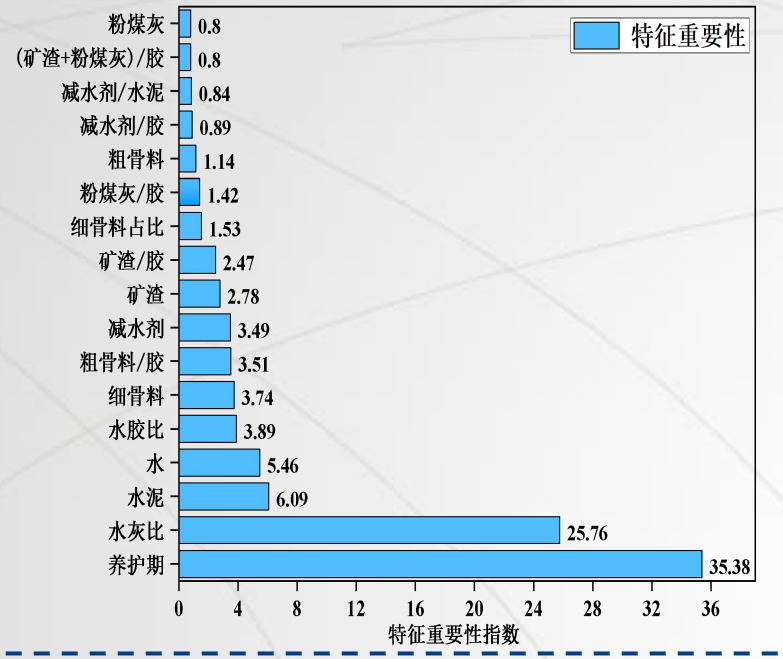

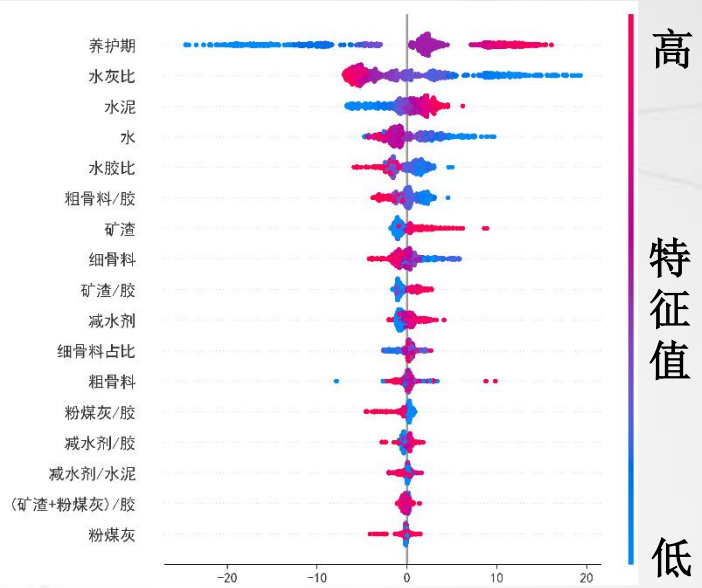

SHAP值(对模型输出的影响)

实际强度为19.01 Mpa

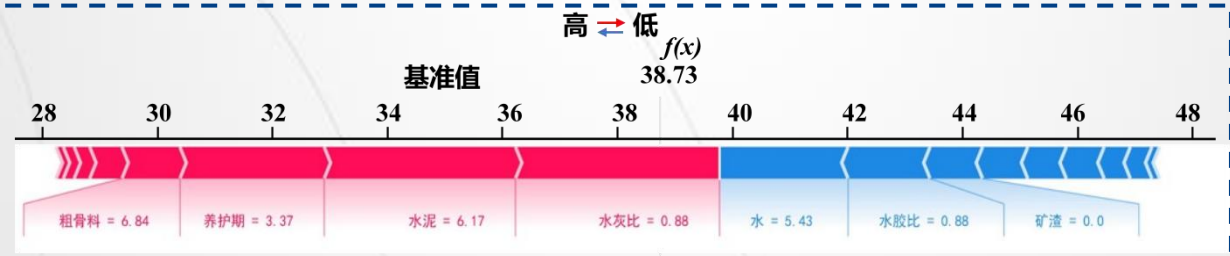

实际强度为34.4 Mpa

图像分类

- 基于ResNet50进行图像数据分类并使用SHAP对分类模型进行解释性分析。其中，使用到的数据集为ImageNet;

安装：

```
pip install shap or  conda install -c conda-forge shap
```

部分代码：

```
import numpy as np
import tensorflow as tf
import shap, json
from tensorflow.keras.applications.resnet50 import ResNet50, preprocess_input

# 加载预训练的模型/载入数据
model = ResNet50(weights='imagenet')
X, y = shap.datasets.imagenet50()

# 获取数据集的类别名
url = "https://s3.amazonaws.com/deep-learning-models/image-models/imagenet_class_index.json"
with open(shap.datasets.cache(url)) as file:
    class_names = [v[1] for v in json.load(file).values()]
#print("Number of ImageNet classes:", len(class_names))
#print("Class names:", class_names)
```

图像分类

使用：

```
# define a masker that is used to mask out partitions of the input image.
masker = shap.maskers.Image("inpaint_telea", X[0].shape)

# create an explainer with model and image masker
explainer = shap.Explainer(f, masker, output_names=class_names)

# here we explain two images using 500 evaluations of the underlying model to estimate the SHAP values
shap_values = explainer(X[1:3], max_evals=100, batch_size=50, outputs=shap.Explanation.argsort.flip[:4])
```

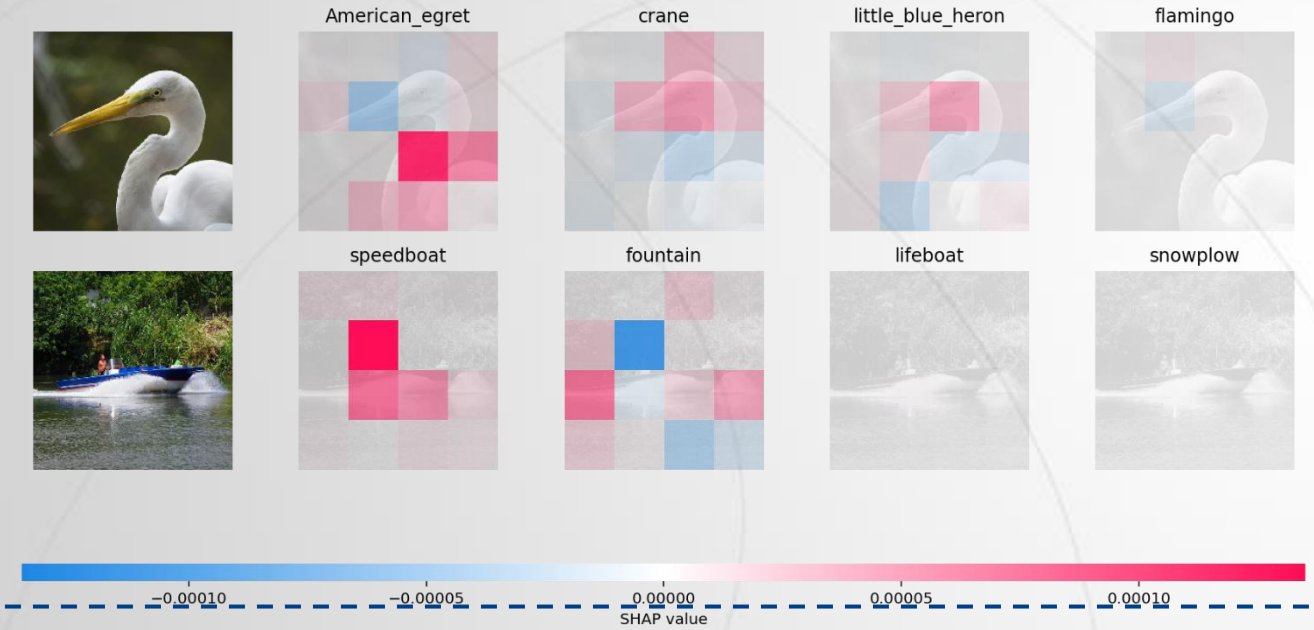

CONTENTES

目录

01 研究动机(Motivation)

02 研究方法(Methology)

03 应用案例(Application)

04 总结致谢(Acknowledgement)

4. 总结致谢——总结

中国交建 CHINA COMMUNICATIONS CONSTRUCTION

总结

- 尽管机器学习在许多领域取得了巨大的成功，但缺乏可解释性严重限制了其在现实任务尤其是**安全敏感与高风险决策**任务中的广泛应用。为什么大多数学习模型都仅仅为辅助决策?

- 一般而言，可以从两个角度对AI的可解释性进行理解，一是要理解算法本身，也就是要对AI的系统功能进行全局解释；二是要理解算法的特定输出，也就是要对AI运作中的特定决策进行局部解释。
- 发展现状，机器学习流程由于有人工经验参与的特征工程，其本身具有一定的可解释性；而深度学习，由于网络层次的加深，模型复杂度更高而难以理解。但面向深度神经网络的可解释性算法已经初步形成了研究体系。
- 存在的问题，现有可解释性方法大多以人为中心，是否具有可解释性方法本身的评估指标？解释的对不对？解释的有多对?

中国交建
CHINA COMMUNICATIONS CONSTRUCTION

谢谢观看

THANKS